OpenPreprint Kit: GitHub 上の論文・研究データを検証可能にする公開キット

Unjuno

2026 年 11 月 13 日 / v1 公開候補 / 未査読

要旨

OpenPreprint Kit は、GitHub を公開基盤とし、論文 PDF・公開研究データ・解析コードを版ごとに結合して検証するオープンソースのキットである。内容のハッシュ、RFC 3161 時刻証明、公開取得の署名記録、GitHub Releases による複製を組み合わせ、内容整合性・存在時刻・公開観測を異なる主張として扱う。本短報は設計と制約を記述し、固定した実装コミットの継続的インテグレーション（CI）ログを再集計する。26 試験モジュールの 274 件が成功したが、これは指定した試験集合に対する結果であり、独立監査や実公開の実証ではない。本稿自体を最初の自己適用対象とし、原稿、試験ログ、集計データ、再計算コードを一体として検証する。自分で構築したキットを自分の論文に適用することは利用上の欠陥を発見する手段になるが、外部査読の代わりにはならない。

キーワード: プレプリント、研究データ、来歴、RFC 3161、GitHub、再現性

1. 背景と目的

研究成果を GitHub の公開リポジトリに置くと、本文・コード・データを同じ版管理の下で扱える。一方、Git の著者日時とコミッター日時は環境変数等で指定できるため、それだけで第三者に対する存在時刻の証拠にはならない [1]。これは利用者が GitHub サーバーの受信日時を自由に改変できるという主張ではない。

本キットの目的は、新しい暗号方式を提案することではなく、既存の仕組みを研究公開の工程に統合することである。特に「何を公開したか」「どのデータ・コードに対応するか」「何を検証したか」を機械可読にする。データの来歴、明確な利用条件、再利用可能な補助資料は FAIR 原則の考え方と関連するが、本実装をもって FAIR 適合認証を主張するものではない [2]。

2. 設計と信頼の境界

原則は一つの論文に一つの公開リポジトリを割り当て、訂正時は新しい版を作ることである。公開用バンドルには PDF、固定された書誌情報、CITATION.cff、BibTeX、ファイル一覧、SHA-256 チェックサムを含める。研究データや解析コードが宣言されている場合には、個別ハッシュと関係を記録した JSON および決定的な TAR を追加する [3]。

層	検証する主張	必要な信頼・限界
内容照合	取得したバイト列が固定対象と一致する	ハッシュの信頼できる取得経路が必要
存在時刻	指定内容のダイジェストに TSA が時刻を付した	TSA、証明書連鎖、失効情報への信頼が必要
公開観測	観測者が指定版を匿名取得したと署名した	観測者の正直さ・独立性は署名だけでは分からない
保存・複製	保管済み資産を照合し復元できる	同じ GitHub 上の複製は基盤障害を共有する

RFC 3161 の要求・応答では、メッセージの指紋、nonce、ポリシー識別子、署名、証明書および失効情報を検証する。署名された時刻精度が記載されない場合、誤差をゼロと仮定しない [4]。論文の公開日時・著作者の同一性・内容の正しさは、これらの検証とは別である。

GitHub の Immutable Releases は公開後のタグと添付資産を固定し、Release attestation を提供する。ただし説明文等は編集可能であるため、論文の書誌情報を説明欄だけに依存させない [5]。公開処理は下書きへの添付、再取得、バイト照合、時刻証拠の再検証を経てから公開に進む。必要な権限や不変設定を確認できない場合は停止する [3]。

3. 研究データと非公開記録

公開するデータとコードは明示的に列挙し、種類、説明、ライセンス、公開確認、解析関係を記録する。列挙漏れ、パストラバーサル、危険なアーカイブ要素、曖昧な重複 YAML キー等を拒否する。PDF の構造検査は行うが、PDF/A 認証やマルウェア不存在を保証しない [3]。

健康記録などの非公開原本は公開リポジトリに置かない。任意の照合機能は、原本と記録ごとの秘密鍵を外部に保持し、HMAC-SHA256 の照合情報だけを扱う。原本と鍵を受け取る権限のある検証者が一致を確認できるが、共有秘密を使うため、誰が原本を作成したかの否認防止にはならない。本人同意、アクセス制御、記録の医学的正しさは別途必要である。本稿の評価には実患者データを使用しない。

4. 評価方法と再現可能な結果

4.1 対象と手順

評価対象を実装コミット `940d0d06d957cd0708f644a595911bdbc3fffa64` に固定した。GitHub の品質 CI が生成したソースとログを取得し、ソース配布物の内容が当該試験対象と一致することを照合した。原ログを `data/baseline-ci.txt.gz` として保持し、圧縮前後の SHA-256 と取得元を `data/provenance.json` に記録した [3,6]。

集計には標準ライブラリだけで動く `analysis/summarize_ci.py` を使用する。試験名の重複、最終総数との不一致、失敗・スキップされた試験、ログ指紋の不一致を拒否する。論文追加後の試験件数で古い評価を上書きせず、対象コミットを固定する。

4.2 結果

保存した品質 CI ログの実行環境は Python 3.12.16、OpenSSL 3.0.13 である。試験は 26 モジュール・274 件で、最終結果は成功、スキップは 0 件だった。次表は元の試験モジュールを機能別に再集計したものであり、成功率の母集団を推測するものではない。全モジュール別の内訳は `data/test-counts.csv` に含める。

試験の区分	件数
時刻証明・更新・観測・統合検証	80
公開データ・非公開照合・履歴	22
保存・保管監査・GitHub 複製	51
Release・公開前検査・管理設定・公開試験	43
メタデータ・入力強化・PDF・引用形式	32
レビュー記録・読者ページ	24
依存固定・ワークフロー・試験用入力等	22
合計	**274**

暗号試験には一時的な認証局・実署名・合成ファイルを使用する。一部の GitHub 通信は模擬応答であるため、CI 成功を実際の不変 Release 公開成功に読み替えない。試験時間は共有実行環境に依存し、本稿では性能ベンチマークを主張しない。

4.3 自己適用プロトコル

最初の適用対象を本稿にする。本文の PDF、上記ログ、再集計データ、解析コードをキットに渡し、固定された公開候補バンドルを作る。原稿自身のハッシュを原稿内へ再帰的に書き込むことは避け、生成後のハッシュと検証結果は別の検証記録に保存する。作成時には、組版ツールが既定で出力したページ表示用 OpenAction がキットの保守的な PDF 検査で拒否された。検査を緩めず、組版時にこの設定を付与しないよう修正し、構造検査の通過を確認した。

H（仮説）は、同じ入力で同じ研究資産が得られ、固定後の PDF・データ・一覧の改変を検出できることとする。T（最小検証）は正常系一式、PDF 変更、研究データ変更、一覧変更、欠落の各異常系である。D（判定）は正常系の成功と全異常系の拒否を局所的な PASS とし、外部時刻証明・公開 Release・独立観測がなければ、その主張は未検証とする。C（対立条件）は同一コードによる共通誤り、信頼根の誤設定、全ファイルと指紋の同時差し替えである。U（不確かさ）は TSA 精度、機械の時計、失効情報の鮮度、観測者と保管者の独立性であり、本稿では合成標準不確かさを数値化できない。

5. 限界と今後の検証

本稿は設計報告と内部評価であり、独立した人間のセキュリティ監査ではない。274 件の決定的試験は未試験入力に対する誤受理確率を与えない。SHA-256、RFC 3161、Ed25519 の安全性を本試験から証明するものでもない。

時刻証拠の更新は、現在検証可能な古い証拠を新たな証拠へ結合する前方更新である。失効・期限切れの古い証拠が自動的に有効へ戻ることや、完全な歴史的長期検証は保証しない。GitHub 上の別リポジトリへの複製は、管理者を分けても GitHub 基盤自体のリスクを共有する。

本稿作成時点で、正式な論文 Release、外部運用者による公開観測、独立査読、長期運用の受入は未完了である。これらの不足を隠して完成宣言をするのではなく、本稿を最初の実利用ケースとして公開・訂正・再検証の記録を蓄積する。

6. 結論

OpenPreprint Kit は、学術公開、暗号学・公開鍵基盤、ソフトウェア品質管理、デジタル保存を接続する実装である。主な成果は、論文と研究資産を一括して固定し、検証できた範囲と信頼上の仮定を区別する工程にある。本稿を自己適用することで、抽象的な機能一覧ではなく、読者が原稿・データ・コードを取得して確かめられる最初の事例を形成する。外部の公開観測や独立監査は、その後も別の検証として必要である。

著者・AI 支援・公開状態

本稿は AI 支援で作成した v1 公開候補である。2026 年 11 月 13 日、利用者の明示的な回答により、著者表示を「Unjuno」、本文・原稿のライセンスを Creative Commons Attribution 4.0 International（CC BY 4.0）に確定した。所属・学位・ORCID・人間の査読者は推定していない。このチャットでの承認を本人確認・著作権の独立証明とはみなさない。ソフトウェアとログのライセンスは添付の資産別宣言に従う。試験結果の正確性と説明の妥当性について、人間の最終確認と独立レビューを推奨する。原稿ソースの GitHub 掲載や TSA 署名だけでは、不変 Release としての正式公開または査読済みを意味しない。

参考資料

[1] Git Project. *git-commit documentation*. 著者日時・コミッター日時の指定。https://git-scm.com/docs/git-commit（2026-11-12 確認）.

[2] Wilkinson, M. D., et al. *The FAIR Guiding Principles for scientific data management and stewardship*. Scientific Data 3, 160018 (2016). DOI: 10.1038/sdata.2016.18.

[3] OpenPreprint Kit. 評価対象ソース、コミット 940d0d06d957cd0708f644a595911bdbc3fffa64. https://github.com/Unjuno/openpreprint-kit/tree/940d0d06d957cd0708f644a595911bdbc3fffa64 .

[4] Adams, C., Cain, P., Pinkas, D., Zuccherato, R. *Internet X.509 Public Key Infrastructure Time-Stamp Protocol (TSP)*. RFC 3161 (2001). DOI: 10.17487/RFC3161.

[5] GitHub. *Immutable releases*. https://docs.github.com/en/code-security/concepts/supply-chain-security/immutable-releases （2026-11-12 確認）.

[6] OpenPreprint Kit. 品質 CI 実行 43222595349、検証 CI 実行 43222595159. https://github.com/Unjuno/openpreprint-kit/actions/runs/43222595349 . 本稿添付の圧縮ログ・来歴 JSON から再集計可能。